

# **Variabilidad espacial de suelo y delineación de zonas de manejo en 2 terrenos agrícolas de Calango aplicando geoestadística y análisis multivariado para uso en agricultura de precisión**

Federico Garland

## **RESUMEN**

El objetivo del presente estudio fue analizar la variabilidad espacial de distintas propiedades del suelo y delinear zonas de manejo agrícola en dos terrenos de Calango. Para ello, se extrajeron muestras de suelo georreferenciadas de los dos terrenos, que fueron analizadas en laboratorio para determinar la textura, humedad, conductividad eléctrica, pH y contenido de materia orgánica. La mayoría de las propiedades mostró una variación considerable ( $CV > 15\%$ ). Posteriormente, se utilizó la interpolación geoestadística Kriging para generar mapas de distribución espacial de cada propiedad de suelo, obteniéndose modelos con un grado de error aceptable en la mayoría de los casos ( $nRMSE < 30\%$ ). Asimismo, se generó un mapa de pendientes a partir de un modelo de elevación digital (DEM). Luego, se realizó un análisis de componentes principales para resumir la variabilidad de los datos, y se escogieron los componentes principales (PCs) con eigenvalue  $> 1$  para la delineación de las zonas de manejo. En los dos terrenos se obtuvieron 3 PCs que cumplían dicha condición. Se aplicó el algoritmo de agrupamiento “Fuzzy c means clustering” a las puntuaciones de los PCs para obtener las zonas de manejo. La cantidad óptima de zonas en cada terreno se determinó según los índices FPI y NCE, obteniéndose una cantidad óptima de 2 zonas en ambos terrenos. Las propiedades del suelo entre las zonas fueron comparadas a través de las pruebas t y Mann-Whitney-Wilcoxon, obteniéndose diferencias significativas para la materia orgánica, textura, humedad y pendiente. Las medidas descriptivas obtenidas para cada zona pueden ser utilizadas como referencia para la planificación del manejo agrícola y aplicación de insumos, a fin de optimizar la producción tanto en términos económicos como ecológicos.

## **1. INTRODUCCIÓN**

La condición del suelo es un factor que afecta directamente la productividad agrícola. El desarrollo de las plantas varía en función a propiedades edafológicas como pH, conductividad eléctrica, textura, humedad, concentración de nutrientes, entre otras (Yuan et al., 2016; Stavridou et al., 2016; Diatta et al., 2018, Dahler & McDole, 1987). Usualmente, el manejo agrícola (fertilización, riego, enmiendas de suelo, etc.) se realiza considerando los valores de dichas propiedades como si afectaran a todo el terreno de forma uniforme. Sin embargo, el suelo tiende a presentar variabilidad espacial, es decir, sus propiedades toman valores diferentes en distintas zonas del terreno. Esto sucede por factores como

la naturaleza de la roca madre, sucesos pedogenéticos o de formación de suelo, pendiente, manejo agronómico, agroecología, hidrología, entre otros (Jaramillo, 2016; Ali & Ibrahim, 2020).

El desconocimiento de la variabilidad espacial de las propiedades del suelo genera problemas de ineficiencia por sobre y subaplicación de insumos como fertilizantes, enmiendas de suelo y riego (Sigua & Hudnall, 2008). Por un lado, la sobreaplicación ocasiona problemas como el aumento de los costos, daños al ambiente y menor desarrollo vegetal por antagonismos nutricionales, toxicidad, etc. Por otro lado, la subaplicación disminuye los rendimientos y la salud vegetal dado que no satisface las necesidades nutricionales, hídricas o edáficas del cultivo. Por ello, la agricultura de precisión busca conocer y manejar adecuadamente la variabilidad espaciotemporal que afecta a los cultivos para aumentar la productividad y sostenibilidad (Khan, 2020).

En ese contexto, la geoestadística es una herramienta que permite estimar la distribución espacial de cada propiedad del suelo a partir de la extracción y análisis en laboratorio de muestras georreferenciadas. Con base en estos datos, pueden utilizarse técnicas de interpolación geoestadística como Kriging para estimar los valores de una variable en cada punto del terreno y así generar mapas continuos de distribución espacial (Gaster & Schnug, 2007, Sigua & Hudnall, 2008). Asimismo, a través del análisis multivariado se puede delinear zonas de manejo en el terreno que agrupan la variabilidad más importante de todas las propiedades del suelo, utilizando como base las estimaciones obtenidas por los modelos geoestadísticos de interpolación (Metwally, 2019).

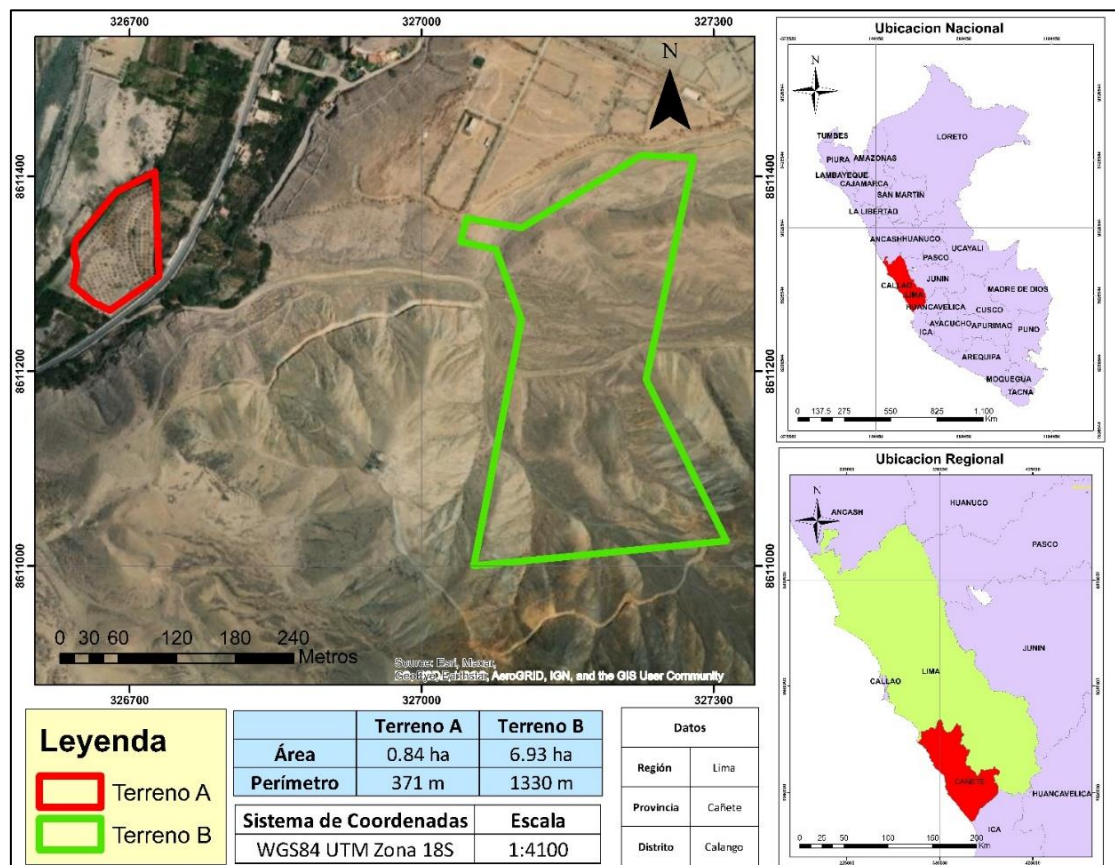
El uso de zonas de manejo para la aplicación de insumos agrícolas permite aumentar los rendimientos y disminuir los costos (Zeraatpisheh, 2020). Por ello, el objetivo de este proyecto fue evaluar la variabilidad y distribución espacial de las propiedades del suelo y delinear zonas de manejo en dos terrenos del Fundo Calango perteneciente a la Universidad Científica del Sur, Perú.

## **2. METODOLOGÍA**

### **2.1. Lugar de estudio**

El área de estudio está comprendida por 2 terrenos ubicados en el distrito de Calango, provincia de Cañete, región de Lima, Perú. El terreno A presenta una superficie de 0.84 ha y cuenta con un cultivo de mandarina, mientras que el terreno B abarca 6.93 ha de suelo eriazo. La distancia entre los dos terrenos es de menos de 1 km.

**Figura 1. Ubicación del lugar de estudio**



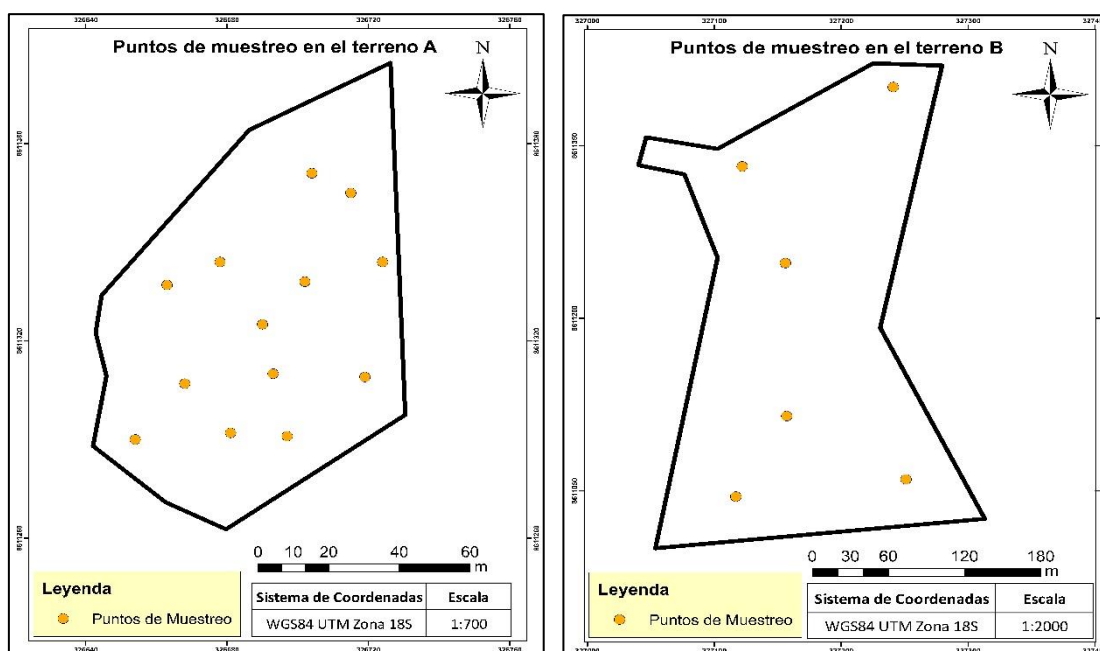
## 2.2. Muestreo

Se extrajeron muestras de suelo georreferenciadas de los dos terrenos para analizar sus propiedades fisicoquímicas. Las ubicaciones de los puntos de muestreo fueron generadas aleatoriamente utilizando una grilla de rejilla en ArcGIS, dado que Houlong et al. (2016) encontró que este método de muestreo genera resultados precisos en la evaluación de suelos. Sin embargo, al llegar a campo se encontraron problemas para seguir el muestreo establecido en las grillas. En el caso del Terreno A, el polígono utilizado en ArcGIS para el muestreo resultó ser más grande que el polígono real por un error en los datos del registro predial, por lo que gran cantidad de puntos de la grilla quedaron ubicados fuera de los límites del terreno. En el caso del Terreno B, se encontró que gran parte de los puntos estaban ubicados en zonas inaccesibles por una topografía accidentada. Por ello, el muestreo tuvo que ser adaptado, se utilizaron los puntos viables de la grilla y el resto de las muestras se obtuvieron de puntos manualmente escogidos al azar. Finalmente, en el terreno A se extrajeron 13 muestras para una densidad de 15.5 muestras/ha, mientras que en el terreno B

se extrajeron 6 muestras para una densidad de aproximadamente 0.1 muestras/ha. La densidad en el terreno A es mayor a las utilizadas por Zeeratpisheeh et al. (2020), Metwally et al. (2019), Ali e Ibrahim (2020) y Ramos et al. (2017), mientras que la densidad de muestreo en el terreno B esta debajo del rango utilizado en esos estudios.

Para ubicar y trasladarse a cada punto se utilizó un GPS. En cada punto de muestreo se obtuvieron 5 submuestras, una en el centroide y 4 a 1m de distancia de este en dirección a los puntos cardinales. Por tanto, cada muestra de suelo está compuesta de 5 submuestras. Las muestras de suelo se extrajeron a una profundidad de 0-30 cm utilizando una pala, las rocas fueron descartadas y las muestras almacenadas en bolsas de plástico, tal como realizo Metwally et al. (2019).

**Figura 2.** *Puntos de muestreo en los terrenos A y B*



### 2.3. Análisis fisicoquímico

Las propiedades fisicoquímicas evaluadas fueron la humedad, textura (arena, limo y arcilla), pH, conductividad eléctrica (CE) y contenido de materia orgánica (MO). Se eligieron estas propiedades porque se ha encontrado que tienen influencia sobre los rendimientos y son utilizadas para la planificación de manejo agrícola (Juhos et al., 2015). Asimismo, se escogieron propiedades físicas como la textura porque estas tienden a ser más permanentes en el tiempo y proporcionan información para el manejo a largo plazo (Schenatto et al., 2016; Kerry & Oliver, 2003). Las propiedades químicas se escogieron porque a pesar de que tienden a ser menos permanentes en el tiempo, son las que suelen presentar mayor variabilidad espacial (Jaramillo, 2015).

La humedad se evaluó por método gravimétrico a 105°C por 24 horas en el horno como realizado por Khan et al. (2020). La textura se evaluó utilizando el

hidrómetro de Bouyoucos por el método de partículas en suspensión siguiendo los procedimientos del Instituto Nacional de Innovación Agraria (INIA, 2017). El pH y conductividad eléctrica se evaluaron en una suspensión suelo-agua en proporción 1:2.5 de acuerdo con el procedimiento realizado por Zeraatpisheh et al. (2020). Para ello se utilizó un pH-metro Hanna-HI98127 y un conductímetro Hach-HQ440d. La materia orgánica se evaluó por el método de pérdida por ignición a una temperatura de 550 °C por 3 horas en una mufla, en concordancia con lo sugerido por Hogsteen et al. (2015).

Los datos de conductividad eléctrica obtenidos en dS/m para solución 1:2.5 fueron transformados a unidades de conductividad eléctrica en dS/m en pasta saturada, haciendo uso de siguiente ecuación de regresión encontrada para suelos arenosos por Sonmez et al. (2008), con un  $R^2 = 0.99$ :

$$ECe = 4.34 * y + 0.17$$

Donde:

ECe: Conductividad eléctrica en dS/m en pasta saturada

Y: Conductividad eléctrica en dS/m en suspensión 1:2.5

## 2.4. Análisis exploratorio

Se obtuvieron los estadísticos descriptivos para cada variable en cada uno de los terrenos. Se calculó el coeficiente de variación (C.V.) y se interpretó el grado de variabilidad de cada propiedad del suelo según los rangos establecidos por Wilding (1985), donde C.V. < 15% indica baja variabilidad, C.V. entre 15-35% indica moderada variabilidad, y C.V. > 35% indica alta variabilidad. Se generaron diagramas de caja de cada variable en términos de puntuación Z para identificar valores extremos. Asimismo, se utilizó la prueba de Shapiro-Wilk con un nivel de significancia de 5% ( $p < 0.05$ ) para confirmar que los datos de cada variable sigan una distribución normal, que es un supuesto que debe cumplirse para la interpolación geoestadística Kriging. En los casos donde las variables no siguieron una distribución normal, se realizó una transformación Box-Cox para normalizar los datos (Osborne, 2010).

La fórmula de la transformación Box-Cox es la siguiente:

$$y = \frac{x^\lambda - 1}{\lambda}$$

Donde:

y: Datos transformados

x: Datos originales

$\lambda$ : Valor de lambda que genera la mejor aproximación a la distribución normal

Asimismo, se generó una matriz de correlación de coeficientes Pearson entre cada variable para ambos terrenos. El análisis exploratorio fue realizado en el lenguaje de programación R.

Por otro lado, los datos de cada variable fueron sometidos a un análisis de tendencias en ArcGIS para encontrar patrones de distribución espacial en direcciones geográficas determinadas (como Norte-Sur o Este-Oeste), para determinar si debe realizarse previamente una eliminación de tendencias (“detrending”) para cumplir el supuesto de estacionariedad necesario para Kriging (Jaramillo, 2012). Finalmente, se generó un mapa de pendiente a partir de un Modelo de Elevación Digital (DEM) generado en el software GlobalMapper.

## **2.5. Análisis geoestadístico**

Se generaron mapas de distribución espacial de cada variable en los respectivos terrenos. Para ello, se aplicó el método de interpolación Kriging. En el caso de las variables que no presentaron una distribución normal ( $p < 0.05$  en Shapiro-Wilk), se realizó una transformación Box-Cox antes de aplicar la interpolación. Kriging es un método geoestadístico de interpolación para modelar la variabilidad espacial de cada propiedad del suelo, estimando sus valores en puntos no medidos, a partir de los valores en puntos medidos. Para ello, en primer lugar, debe ajustarse un semivariograma teórico a los datos, que describe la relación entre la semivarianza de todos los pares de puntos muestreados y la distancia entre ellos. Luego, la estimación de los valores en los puntos no medidos se realiza en función a los valores medidos en puntos vecinos y los pesos Kriging asignados a cada uno de ellos. A su vez, los pesos Kriging se determinan en función a la semivarianza existente para la distancia entre cada punto vecino y el punto estimado, obtenida del semivariograma teórico (Szatmári & Pásztor, 2016; Laekemariam et al., 2018; Bodaghabadi, 2018).

La semivarianza se calcula a través de la formula:

$$\hat{\gamma}(h) = \frac{1}{2N} \sum_{i=1}^n [z(x_i) - z(x_i + h)]^2$$

Donde:

h: Distancia entre pares de puntos muestreados (conocida como “lag distance”)

N: Cantidad de pares de puntos a una distancia h

$Z(x_i)$ : Valor de la variable en el punto  $X_i$

$\hat{\gamma}(h)$ : Semivarianza promedio a una distancia h

Una vez obtenida la semivarianza para cada intervalo de distancia (lag) y ajustado el semivariograma teórico a los datos, se realiza la interpolación Kriging.

La fórmula de Kriging es la siguiente:

$$Z(u) = \sum_{i=1}^N \lambda_i * Z(u_i)$$

Donde:

$Z(u)$ : Valor de la variable en el punto estimado  $u$

$Z(u_i)$ : Valor de la variable en el punto vecino  $u_i$  (punto muestreado)

$\lambda_i$ : Peso Kriging para el  $i$  punto vecino, calculado a partir de la semivarianza

$N$ : Cantidad de puntos vecinos

Los modelos obtenidos fueron ajustados a través de una validación cruzada de tipo "Leave-One-Out Cross-Validation" (LOOCV) buscando minimizar los parámetros de error medio (ME) y raíz del error cuadrático medio (RMSE) que cuantifican la diferencia entre los valores reales y los valores predichos por el modelo en cada punto muestreado.

$$ME = \frac{1}{n} \sum_{i=1}^n (P_i - O_i)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (P_i - O_i)^2}$$

Donde  $n$  es igual al número de puntos muestreados,  $P_i$  es el valor predicho en el punto  $i$  y  $O_i$  es el valor medido en el punto  $i$ .

Para el ajuste de los modelos, se alteraron parámetros como las características del semivariograma y el vecindario de búsqueda, hasta alcanzar los valores mínimos de ME y RMSE. Finalmente, se obtuvieron los parámetros de mejor ajuste para cada semivariograma y la calidad de los modelos fue interpretada en base al nRMSE según los rangos establecidos por Jamieson et al. (1991), donde  $nRMSE < 10\%$  indica una interpolación excelente,  $nRMSE$  entre 10-20% una interpolación buena,  $nRMSE$  entre 20-30% una interpolación aceptable y  $nRMSE > 30\%$  una interpolación pobre. La fórmula del nRMSE es la siguiente:

$$nRMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (P_i - O_i)^2} * \frac{1}{\bar{X}}$$

Donde  $n$  es la cantidad de puntos muestreados,  $P_i$  el valor predicho en el punto  $i$ ,  $O_i$  el valor medido en el punto  $i$  y  $\hat{X}$  la media de los valores medidos.

Todos los mapas fueron georreferenciados en el sistema de coordenadas WGS84 UTM Zona 18S. El análisis geoestadístico fue realizado en ArcGIS utilizando la herramienta Geostatistical Analyst.

## **2.6. Análisis de componentes principales**

Posteriormente, los datos interpolados de cada propiedad del suelo fueron utilizados para delinear las zonas de manejo a través de un análisis multivariado, tal como sugiere Schenatto et al. (2016). Para ello, los datos fueron estandarizados en términos de puntuación  $Z$  según la siguiente fórmula:

$$Z = \frac{X - \mu}{\delta}$$

Donde  $Z$  es el valor estandarizado,  $X$  el valor original,  $\mu$  la media de la variable y  $\delta$  la desviación estándar. Estos datos estandarizados fueron procesados a través de un Análisis de Componentes Principales (ACP) para crear nuevas variables que resuman la variabilidad y relaciones existentes entre los datos. Estas nuevas variables son llamadas componentes principales, que son combinaciones lineales de todas las propiedades de suelo evaluadas (variables originales). Cada componente principal posee un eigenvalue, que describe la cantidad de variabilidad que este agrupa, donde los componentes con un eigenvalue  $> 1$  explican una mayor cantidad de variación que una variable individual (Sharma, 1996). Se utilizaron las puntuaciones de los componentes principales con un eigenvalue  $> 1$  para realizar la delimitación de zonas a través del clustering, tal como realizaron Ali & Ibrahim (2020), Zeeratpisheh et al. (2020) y Metwally et al. (2019). Asimismo, se determinaron los coeficientes de correlación y valores de  $\cos^2$  entre cada propiedad del suelo y los componentes principales escogidos para poder caracterizar la estructura de dichos componentes, así como la calidad de representación de cada propiedad del suelo por estos. El ACP fue realizado en R.

## **2.7. Clustering**

Las puntuaciones de los componentes principales con eigenvalue  $> 1$  fueron agrupadas a través del algoritmo “Fuzzy c means clustering” para delimitar las zonas de manejo. Los algoritmos de clustering como fuzzy c means permiten segmentar los datos para generar grupos (en este caso zonas) con una alta diferencia entre ellos, y una baja variación dentro de si mismos (Askari et al., 2017; Tsekouras & Sarimveis, 2004). La cantidad óptima de zonas para cada terreno fue determinada a través de los índices Fuzzy Performance Index (FPI) y Normalized Classification Entropy (NCE), donde la cantidad óptima de zonas es aquella donde se consigue minimizar los valores de ambos índices, en concordancia con lo realizado por Zeeratpisheh et al. (2020), Ramos et al. (2017) y Metwally et al. (2019). Las fórmulas para calcular ambos índices son las siguientes:



$$FPI = 1 - s \frac{c}{c-1} \left[ 1 - \frac{\sum_{i=1}^c \sum_{k=1}^n (\mu_{ik})^2}{n} \right]$$

$$NCE = \frac{n}{n-c} \left[ - \frac{\sum_{k=1}^n \sum_{i=1}^c \mu_{ik} \log a(\mu_{ik})}{n} \right]$$

Donde  $c$  es el número de clusters (zonas),  $\mu_{ik}$  es el valor de “fuzzy membership”,  $n$  es el número de observaciones y  $\log a$  es el logaritmo natural. El clustering fue realizado en R.

## **2.8. Descripción y comparación de zonas de manejo**

Una vez obtenidas las zonas de manejo, los puntos originales de muestreo fueron agrupados según su pertenencia a su respectiva zona de manejo. Posteriormente, se compararon las medias de cada propiedad de suelo entre las distintas zonas a través de una prueba  $t$  para muestras independientes con un nivel de significancia de 5% ( $p < 0.05$ ). En los casos donde no hubo diferencia significativa entre las medias, se realizó una prueba no-paramétrica de Mann-Whitney-Wilcoxon para comparar las medianas con un nivel de significancia de 5% ( $p < 0.05$ ), tal como realizó Ramos et al. (2017). Las medidas de tendencia central de cada propiedad del suelo encontradas en cada zona pueden ser utilizadas como referencia para el manejo agrícola y aplicación variable de insumos (Khosla et al., 2008; Nawar et al., 2017; Metwally et al., 2019; Ramos et al., 2017)

## **2.9. Generación de mapas finales**

Los datos del clustering fueron importados a ArcGIS para generar los mapas finales de zonas de manejo en cada terreno, en el sistema de coordenadas WGS84 UTM Zona 18S.

### 3. RESULTADOS

#### 3.1. Análisis Exploratorio

**Tabla 1.** Estadísticos descriptivos para las distintas variables evaluadas en los terrenos A y B

Terreno	Variable	Media	Mediana	DE	Min	Max	Asimetría	Curtosis	C.V.	N
A	Humedad (%)	6.42	5.90	1.82	4.28	9.67	0.86	-1.46	28.36%	0.23
	Arena (%)	65.04	66.05	7.25	55.16	75.66	-0.03	-1.56	11.14%	0.35
	Arcilla (%)	13.14	13.86	2.58	9.04	16.72	-0.19	-1.62	19.67%	0.35
	Limo (%)	21.83	22.10	5.47	13.51	30.98	0.11	-1.30	25.08%	0.66
	M.O. (%)	2.04	2.02	0.42	1.02	2.79	-0.66	0.63	20.59%	0.37
	C.E. (dS/m)	3.47	2.06	3.16	1.45	12.63	1.87	2.54	91.07%	<b>0.00017*</b>
	pH	7.96	7.95	0.26	7.46	8.43	-0.04	-0.80	3.29%	1
	Pendiente	20.87	16.32	11.71	4.89	64.20	1.23	1.11	56.11%	<b>&lt;0.001*</b>
B	Humedad	1.26	1.29	0.37	0.65	1.74	-0.19	-1.23	29.25%	0.85
	Arena (%)	50.68	50.88	10.08	39.81	65.45	0.17	-1.78	19.89%	0.61
	Arcilla (%)	7.03	6.89	2.39	4.39	10.19	0.11	-1.95	34.00%	0.55
	Limo (%)	42.28	43.82	9.56	29.94	52.30	-0.17	-2.04	22.61%	0.34
	M.O. (%)	1.02	1.00	0.20	0.82	1.31	0.22	-1.95	19.25%	0.33
	C.E. (dS/m)	78.24	66.31	39.59	49.24	155.9	1.13	-0.46	50.60%	<b>0.0178*</b>
	pH	7.82	7.82	0.12	7.63	7.96	-0.26	-1.69	1.56%	0.67
	Pendiente (%)	26.37	22.56	13.19	0	79.88	1.27	1.69	50.02%	<b>&lt;0.001*</b>

N: p valor para la prueba de normalidad de Shapiro-Wilk.  
 \*p < 0.05, indica una diferencia significativa entre los datos y la curva de distribución normal.

Según los criterios de descripción de suelos de la FAO (2009), en el terreno A la clase textural del suelo es franco arenosa, con porcentajes de arena, limo y arcilla de 65.04%, 21.83% y 13.14%. Asimismo, presenta un contenido de materia orgánica de 2.04%, que se considera un valor intermedio para suelos de la costa peruana (1.5-2.5%). La conductividad eléctrica fue de 3.47 dS/m en pasta saturada, lo que implica que el suelo es moderadamente salino y puede generar disminuciones de rendimiento en cultivos no tolerantes a esas condiciones. De acuerdo con el valor de pH de 7.96, el terreno A tiene un suelo alcalino, lo que podría generar una reducción en la disponibilidad de nutrientes como P, Fe, Zn, Cu, B y Mn. El terreno es moderadamente escarpado con una pendiente promedio de 20.87%. Respecto a la variabilidad de cada propiedad del suelo en el terreno, según los coeficientes de variación y los rangos de clasificación establecidos por Wilding (1985), la conductividad eléctrica y la pendiente presentan variabilidad alta, la humedad, arcilla, limo y materia orgánica variabilidad moderada, y la arena y el pH variabilidad baja. Solo la conductividad eléctrica y pendiente presentaron valores significativos de asimetría (>1). En cuanto a la normalidad, las únicas variables que presentaron una diferencia significativa ( $p < 0.05$ ) con la distribución normal fueron también la conductividad eléctrica y la pendiente. La pendiente no requiere normalización porque no será procesada a través de interpolación Kriging.

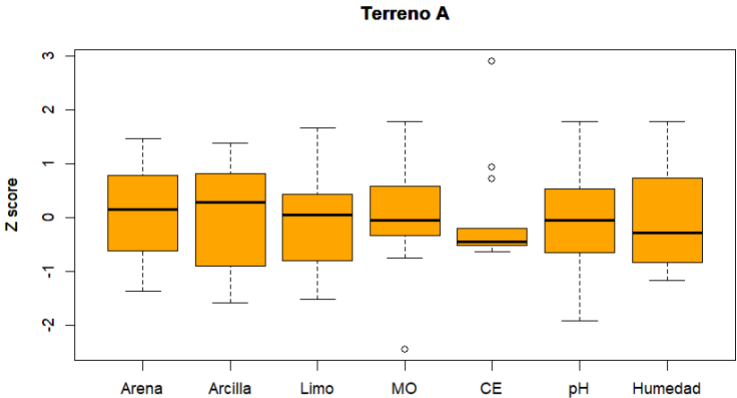
En el terreno B, la clase textural también es franco arenosa con porcentajes de arena, limo y arcilla de 50.68%, 42.28% y 7.82% respectivamente. El contenido de materia orgánica es bajo con un valor de 1.02%, mientras que la conductividad eléctrica en pasta saturada es extremadamente alta con un valor medio de 78.24 dS/m, que implica fuertes restricciones al desarrollo y

rendimiento de la gran mayoría de cultivos. En cuanto al pH, el suelo es alcalino con un valor medio de 7.82, lo que indica posibles limitaciones a la disponibilidad de P, Fe, Zn, B, Mn y Cu. La pendiente promedio fue de 26.37%, por lo que el terreno se puede clasificar como escarpado. En cuanto a la variabilidad, la conductividad eléctrica y la pendiente presentaron variabilidad alta, la humedad, arena, arcilla, limo y materia orgánica variabilidad moderada, y el pH variabilidad baja. Al igual que en el terreno A, las únicas variables donde se halló diferencia significativa ( $p < 0.05$ ) con la distribución normal y que presentaron valores de asimetría mayores a 1, fueron la conductividad eléctrica y la pendiente.

Dado que la C.E. en ambos terrenos difiere de una distribución normal, se procedió a realizar una normalización para cumplir el supuesto de normalidad necesario para la interpolación Kriging.

### 3.2. Normalización

**Figura 3.** Diagramas de caja de las puntuaciones Z para cada variable evaluada en el terreno A



Solo se encontraron valores extremos para la conductividad eléctrica y materia orgánica en el terreno A.

Asimismo, dado que la prueba Shapiro-Wilk demostró que la conductividad eléctrica en el terreno A no sigue una distribución normal, los datos fueron sujetos a una transformación Box-Cox para conseguir que cumplan el supuesto de normalidad de Kriging. El valor optimizado de lambda fue de  $\lambda = -1.27$ . Se realizó una prueba de Shapiro-Wilk para comprobar que los datos transformados no presenten diferencia significativa con una distribución normal.

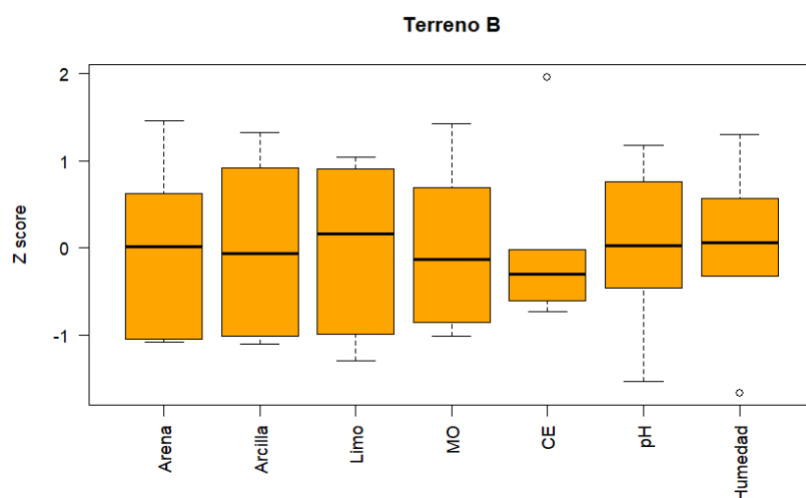
**Tabla 2.** Valores de significancia p para la prueba de normalidad de Shapiro-Wilk a datos inalterados y transformados de conductividad eléctrica en el terreno A.

	Datos originales	Datos transformados
<b>P valor</b>	0.00017*	0.53

\* $p < 0.05$ , indica una diferencia significativa entre los datos y la curva de distribución normal.

Se logró normalizar los datos de conductividad eléctrica en el terreno A, obteniéndose un valor p final de 0.53 en la prueba de Shapiro-Wilk.

**Figura 4.** Diagramas de caja de las puntuaciones Z para cada variable evaluada en el terreno B



En el terreno B, solo la conductividad eléctrica y la humedad presentan valores extremos.

De igual manera, dado que en el terreno B la conductividad eléctrica no cumple el supuesto de normalidad ( $p < 0.05$  en Shapiro-Wilk) se aplicó una transformación Box-Cox a los datos de conductividad eléctrica para normalizarlos. El valor de lambda optimizado fue de  $\lambda = -1.76$ . Se realizó una prueba de Shapiro-Wilk para comprobar que los datos transformados no presenten diferencia significativa con la distribución normal.

**Tabla 3.** Valores de significancia  $p$  para la prueba de normalidad de Shapiro-Wilk a datos inalterados y transformados de conductividad eléctrica en el terreno B.

	Datos originales	Datos transformados
<b>P valor</b>	0.0178*	0.9045

\* $p < 0.05$ , indica una diferencia significativa entre los datos y la curva de distribución normal.

Se logró normalizar los datos de conductividad eléctrica en el terreno B, obteniéndose un valor  $p$  final de 0.9045 en la prueba de Shapiro-Wilk. Los datos transformados fueron utilizados para realizar la interpolación Kriging.

### 3.3. Análisis de correlación

**Tabla 4.** Matriz de correlación para las variables en el terreno A

	Arena	Arcilla	Limo	MO	CE	pH	Humedad
Arena	1	<b>-0.780*</b>	<b>-0.955*</b>	0.548	-0.502	0.331	-0.316
Arcilla	<b>-0.780*</b>	1	<b>0.560*</b>	<b>-0.617*</b>	0.475	-0.036	-0.093
Limo	<b>-0.955*</b>	<b>0.560*</b>	1	-0.434	0.440	-0.421	0.462
MO	0.548	<b>-0.617*</b>	-0.434	1	-0.082	-0.460	0.034
CE	-0.502	0.475	0.440	-0.082	1	-0.410	-0.305
pH	0.331	-0.036	-0.421	-0.460	-0.410	1	-0.176
Humedad	-0.316	-0.093	0.462	0.034	-0.305	-0.176	1

**\*p < 0.05**

Se encontraron coeficientes de correlación significativos entre los 3 tipos de partícula mineral (arena, limo, arcilla). Por otro lado, se halló una correlación negativa moderada significativa entre la arcilla y el contenido de materia orgánica ( $r = -0.617$ ,  $p < 0.05$ ), contrario a lo indicado por la FAO (2020), que afirma que suele haber una relación directa entre la materia orgánica (MO) y la arcilla. No obstante, cabe destacar que hay 2 formas en las que la materia orgánica se acumula en el suelo: como materia orgánica particular o como materia orgánica asociada a minerales (Cotrufo et al., 2019, Lavalley et al., 2019). Schweizer et al. (2021) encontró que la MO particular (MOP) se correlaciona positivamente con la arcilla, mientras que la MO asociada a minerales (MOAM) se correlaciona negativamente con ella. Los resultados de Schweizer et al. (2021) son consistentes con los encontrados en el terreno A, habiéndose encontrado un  $r = -0.592$  (muy cercano al  $r = -0.617$  del terreno A) para la relación entre la MOAM de 0.2 a 2  $\mu\text{m}$  y el contenido de arcilla. Por tanto, la relación entre arcilla y MO encontrada en el terreno A de Calango podría indicar la presencia de MO asociada a minerales con un tamaño de 0.2 a 2  $\mu\text{m}$  (Schweizer et al., 2021). La MOAM está compuesta de moléculas de bajo peso que se encuentran protegidas de la descomposición por la presencia de enlaces químicos con minerales u oclusión en microagregados, por lo que tiende a ser una fuente de carbono de liberación lenta (décadas a siglos), aunque rica en nutrientes como nitrógeno y estimulantes como aminoácidos (Lavalley et al., 2019). Por tanto, podría ser pertinente agregar materia orgánica particular (MOP) al suelo en el terreno A, para brindar una fuente de carbono de descomposición rápida.

**Tabla 5.** Matriz de correlación para las variables en el terreno B

	Arena	Arcilla	Limo	MO	CE	pH	Humedad
Arena	1	-0.333	<b>-0.972*</b>	0.043	-0.003	-0.630	-0.485
Arcilla	-0.333	1	0.101	-0.531	-0.296	-0.012	-0.327
Limo	<b>-0.972*</b>	0.101	1	0.088	0.078	0.668	0.594
MO	0.043	-0.531	0.088	1	-0.409	-0.398	0.484
CE	-0.003	-0.296	0.078	-0.409	1	0.570	0.258
pH	-0.630	-0.012	0.668	-0.398	0.570	1	0.115
Humedad	-0.485	-0.327	0.594	0.484	0.258	0.115	1

**\*p<0.05**

En el terreno B solo se halló un coeficiente de correlación significativo entre el limo y la arena, donde existe una correlación negativa fuerte ( $r = -0.972$ ,  $p < 0.05$ ).

### 3.4. Análisis geoestadístico

Los indicadores de precisión de los modelos generados por interpolación Kriging y los parámetros de los semivariogramas teóricos ajustados a los datos de cada variable se presentan en la tabla 6. El grado de calidad de los modelos de interpolación se determinó en base al nRMSE según los rangos establecidos por Jamieson et al. (1991). La dependencia o autocorrelación espacial es el grado en que los valores de una variable en un determinado punto se correlacionan con los valores de la misma variable en puntos cercanos (Celemín, 2009). Asimismo, el rango del semivariograma es la distancia hasta la que existe autocorrelación espacial para una determinada variable (Metwally et al., 2019; Jaramillo, 2012).

En cuanto al grado de dependencia espacial, está determinado por la relación nugget/sill, donde una relación  $<0.25$  implica una dependencia espacial fuerte causada por factores intrínsecos del suelo como la mineralogía y textura, una relación entre 0.25 y 0.75 implica una dependencia moderada causada por factores intrínsecos y extrínsecos, y una relación  $>0.75$  implica una dependencia espacial débil ocasionada principalmente por factores externos como riego, fertilización, labranza, enmiendas, etc. (Cambardella et al., 1994).

**Tabla 6.** Semivariogramas teóricos e indicadores de precisión de los modelos de interpolación Kriging para las distintas variables evaluadas en los terrenos A y B

Terreno	Variable	Modelo	Nugget	Sill	Range (m)	Nug/Sill	GDE	Error Medio	RMSE	nRMSE	Calidad*
A	Humedad	Esférico	0.0001	0.000256	51.1	39.06%	Media	-2*10 <sup>-7</sup>	0.0178	27.73%	Aceptable
	Arena	Exponencial	18	51	53.6	35.29%	Media	-0.00094	8.2845	12.74%	Buena
	Arcilla	Circular	250	1150	51.3	21.73%	Fuerte	-0.03801	2.5319	19.27%	Buena
	Limo	Cuadrático Racional	5	27	53.6	18.51%	Fuerte	0.18995	6.4987	29.77%	Aceptable
	CE	Esférico	0.0023	0.0323	54	7.12%	Fuerte	-0.021789	3.09958	89.26%	Pobre
	Materia Orgánica	Exponencial	0.009	0.269	80	3.35%	Fuerte	-0.003719	0.41390	20.20%	Aceptable
	pH	Exponencial	0.019	0.076	53.6	25%	Media	-0.002371	0.29981	3.77%	Excelente
B	Humedad	Circular	6*10 <sup>-6</sup>	0.000029	1032	20.97%	Fuerte	0.000051	0.00393	31.19%	Pobre
	Arena	Estable	0	0.07	301.6	0	Fuerte	0.094868	9.68223	19.10%	Buena
	Arcilla	Exponencial	0.0005	0.1505	150	0.33%	Fuerte	0.024944	2.78660	39.64%	Pobre
	Limo	Exponencial	9	139	350	6.47%	Fuerte	0.334473	10.8433	25.65%	Aceptable
	CE	Exponencial	1*10 <sup>-9</sup>	4.9*10 <sup>-8</sup>	370	18.36%	Fuerte	-0.011445	41.1140	52.55%	Pobre
	Materia Orgánica	Exponencial	2*10 <sup>-5</sup>	0.05613	300	0.04%	Fuerte	0.0035088	0.21413	20.99%	Aceptable
	pH	Gaussiano	0	0.018261	415.9	0	Fuerte	0.0361861	0.05985	0.77%	Excelente

\*El grado de calidad está de acuerdo con los rangos establecidos por Jamieson et al. (1991). Las siglas GDE corresponden al grado de dependencia espacial.

En el caso del terreno A, el pH presentó una calidad de interpolación excelente, la arena y la arcilla una calidad buena, la humedad, el limo y la materia orgánica una calidad aceptable y la conductividad eléctrica (CE) una calidad pobre. Asimismo, la arcilla, limo, conductividad eléctrica y materia orgánica presentaron fuerte dependencia espacial, mientras que para la humedad, arena y pH se halló una dependencia espacial media. Por otro lado, el rango fue cercano a los 50 m para todas las variables a excepción de la materia orgánica, donde fue de 80 m. Los semivariogramas teóricos ajustados fueron de tipo exponencial para la arena, materia orgánica y pH, esférico para la humedad y CE, circular para la arcilla y cuadrático racional para el limo. Todas las variables presentaron “efecto nugget”, que puede implicar que las propiedades de suelo varían a distancias menores a las utilizadas para el muestreo, o puede ser causado por errores en el análisis fisicoquímico o en el muestreo (Carrasco, 2010).

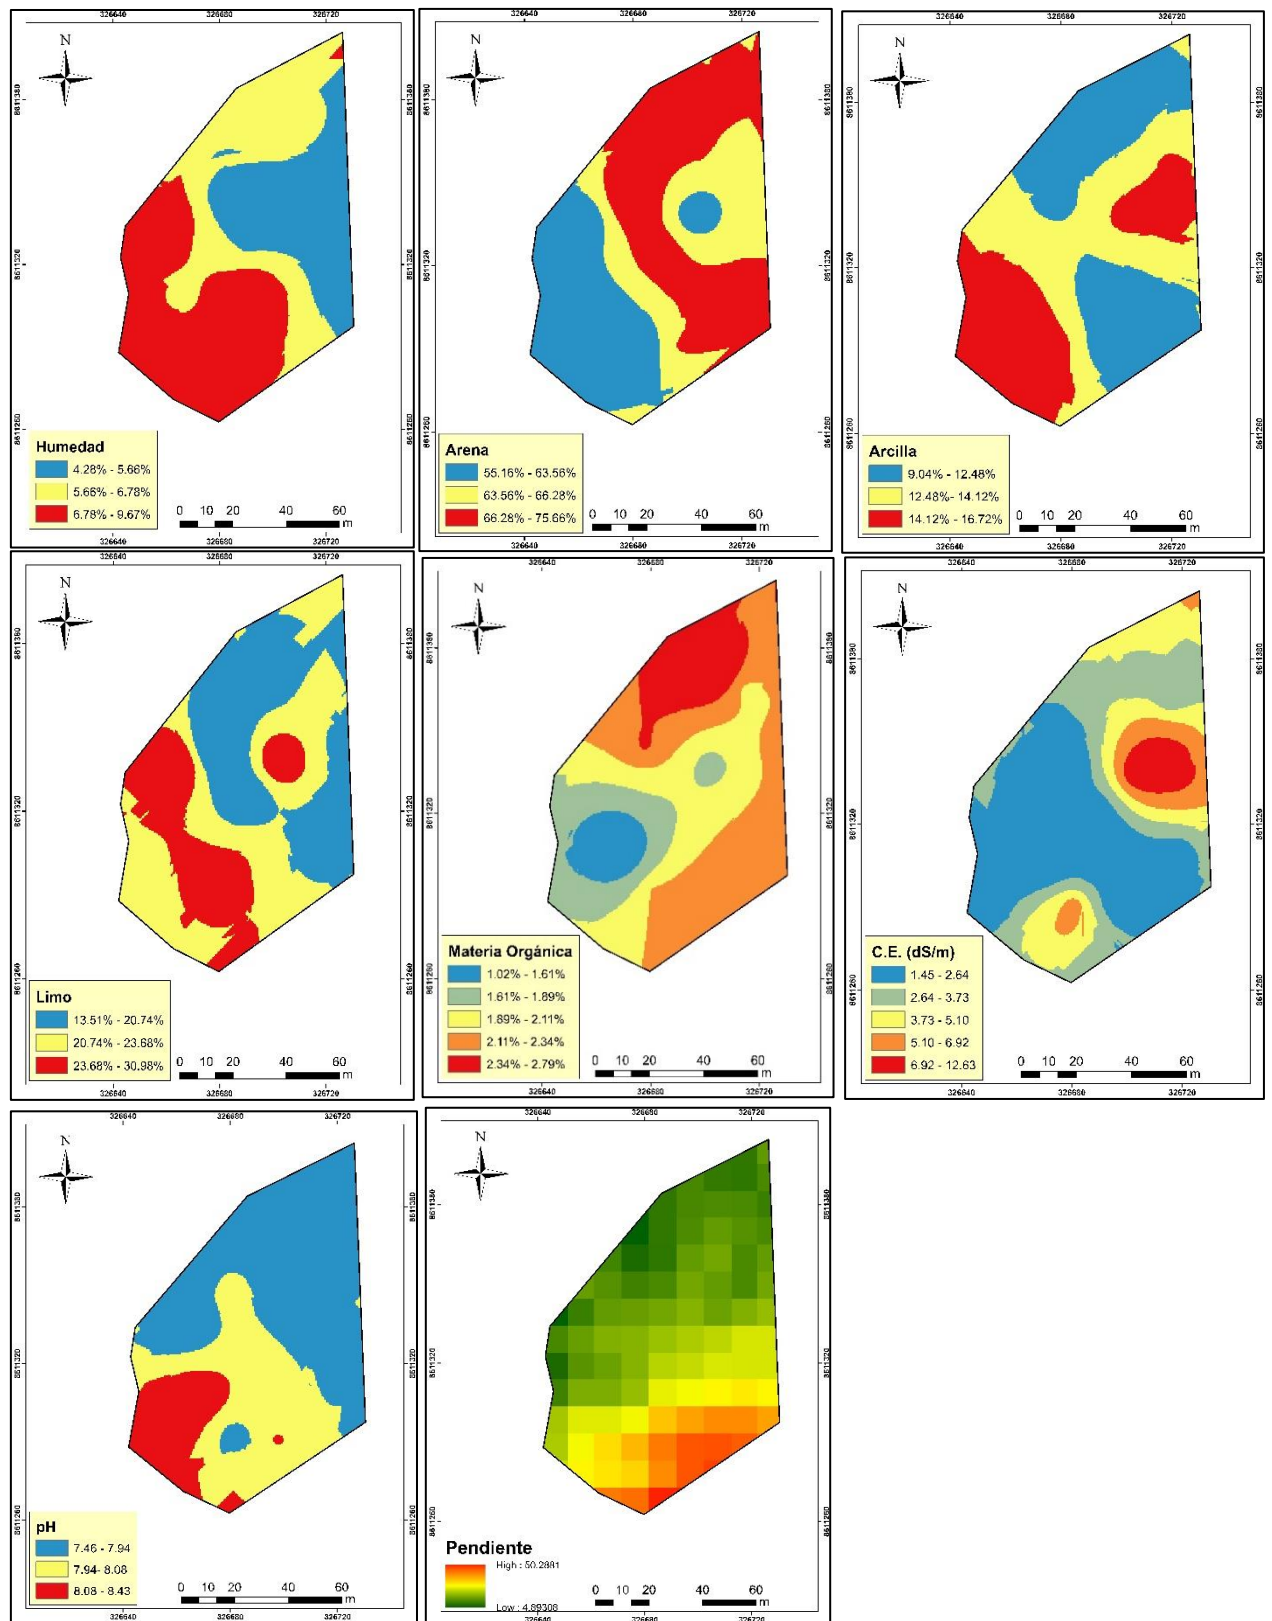
En el terreno B, el pH presentó una calidad de interpolación excelente, la arena una calidad buena, el limo y materia orgánica una calidad aceptable, y la humedad, arcilla y conductividad eléctrica una calidad pobre. Por otro lado, todas las variables presentaron fuerte dependencia espacial. El rango más bajo fue de 150 m para la arcilla, mientras que el más alto fue de 1032 m para la humedad. Los semivariogramas teóricos fueron de tipo exponencial para la arcilla, limo, conductividad eléctrica y materia orgánica, gaussiano para el pH, circular para la

humedad y estable para la arena. Todas las variables a excepción de la arena y el pH presentaron “efecto nugget”.

Dado que es recomendable realizar el muestreo de suelos a distancias menores a la mitad del rango del semivariograma de cada variable (Kerry & Oliver, 2004), los rangos de los semivariogramas obtenidos pueden ser utilizados como referencia para futuros muestreos con fines de análisis de variabilidad espacial en el Fundo Calango.

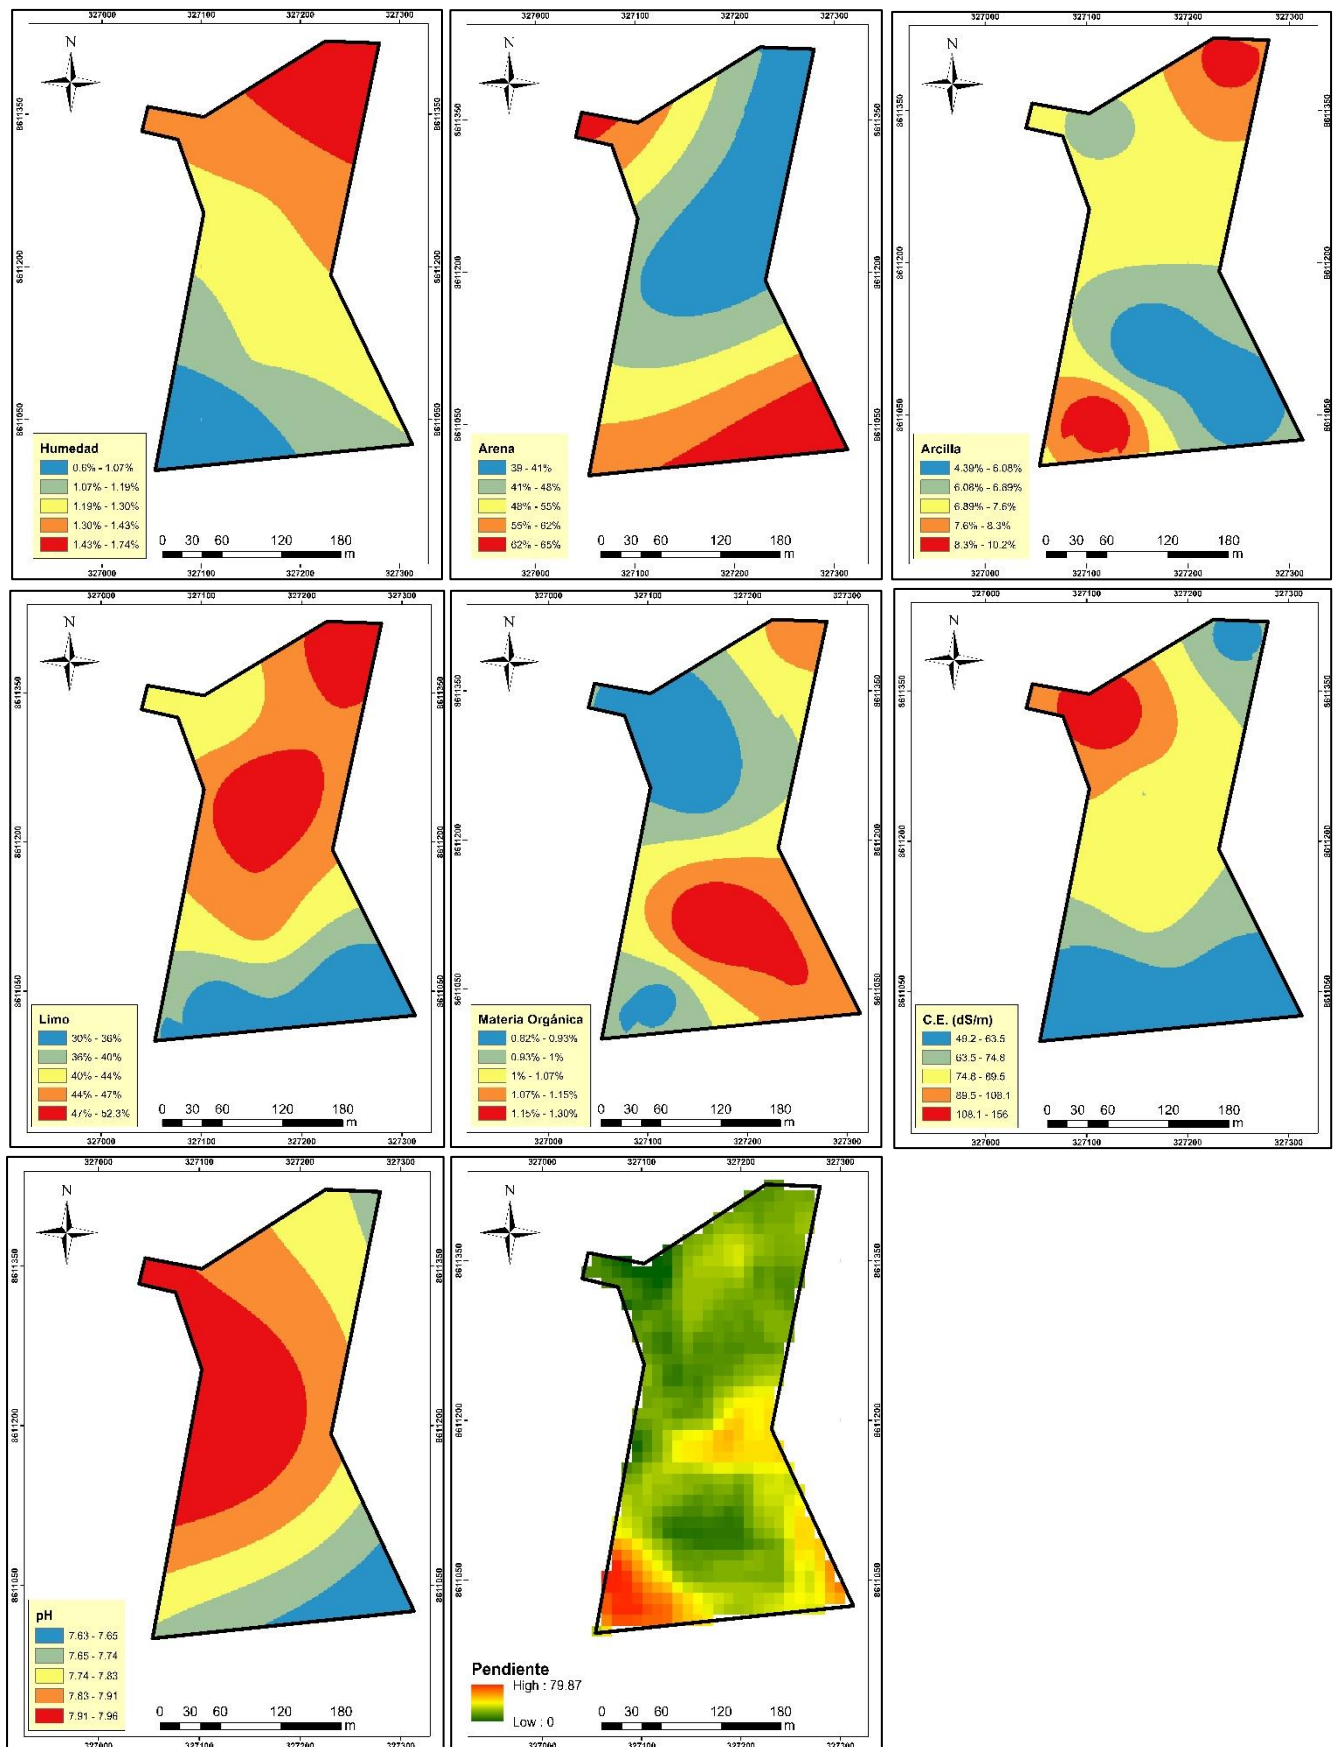


**Figura 5.** Mapas de variabilidad espacial obtenidos por interpolación Kriging para cada propiedad de suelo en el terreno A



\*El mapa de pendiente fue elaborado a partir de un Modelo de Elevación Digital (DEM).

**Figura 6.** Mapas de variabilidad espacial obtenidos por interpolación Kriging para cada propiedad de suelo en el terreno B



\*El mapa de pendiente fue elaborado a partir de un Modelo de Elevación Digital (DEM).

### 3.5. Análisis de componentes principales

#### 3.5.1. Análisis de componentes principales en el Terreno A

**Tabla 7.** Resultados del análisis de componentes principales para el terreno A

Componente Principal	Eigenvalue	Varianza explicada (%)	Varianza explicada acumulada (%)
PC1	<b>3.86</b>	48.28	48.28
PC2	<b>1.75</b>	21.89	70.17
PC3	<b>1.02</b>	12.74	82.91
PC4	0.90	11.30	94.21
PC5	0.26	3.23	97.43
PC6	0.13	1.59	99.02
PC7	0.05	0.65	99.67
PC8	0.03	0.33	100

Para el terreno A, se obtuvieron 3 componentes principales (PCs) con eigenvalue mayor a 1. Estos 3 componentes en conjunto explican el 82.91% de la variabilidad de los datos, donde el PC1 explica el 48.28% de la variabilidad, mientras que PC2 y PC3 explican 21.89% y 12.74% respectivamente. Estos 3 componentes fueron elegidos para delinear las zonas de manejo en el terreno A ingresando sus puntuaciones al algoritmo fuzzy c means clustering.

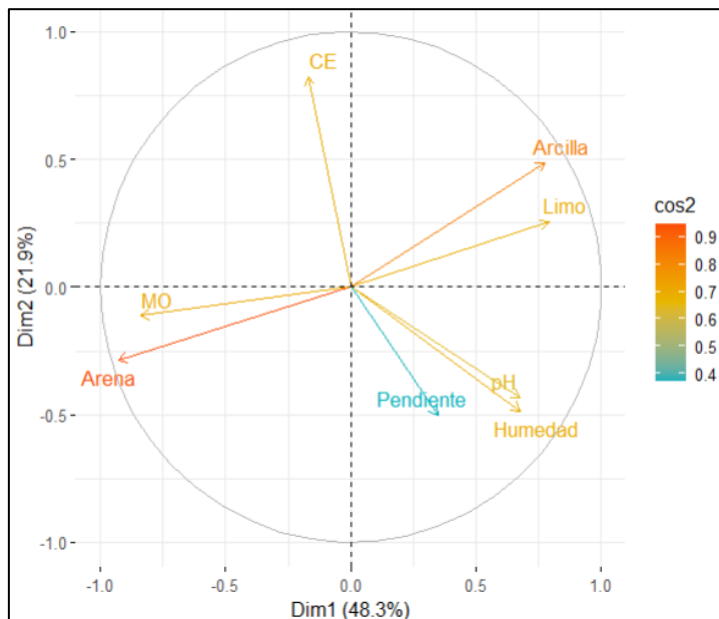
**Tabla 8.** Coeficientes de correlación entre cada variable y los primeros 3 componentes principales en el terreno A

Variables	PC1	PC2	PC3
Humedad	<b>0.68</b>	-0.49	-0.29
Arena	<b>-0.93</b>	-0.29	0.14
Limo	<b>0.79</b>	0.26	-0.43
Arcilla	<b>0.78</b>	0.49	0.23
MO	<b>-0.84</b>	-0.11	-0.44
CE	-0.17	<b>0.82</b>	-0.31
pH	<b>0.68</b>	-0.43	0.36
Pendiente	0.35	<b>-0.50</b>	<b>-0.51</b>

**\*Nivel de significancia  $r > 0.50$ .**

El componente principal 1 (PC1) está relacionado positivamente con la humedad, limo, arcilla y pH, y negativamente con la arena y materia orgánica. Por su parte, PC2 presenta una asociación positiva con la conductividad eléctrica y una asociación negativa con la pendiente. Finalmente, la estructura de PC3 está definida por la pendiente, encontrándose una relación negativa con esta. Los resultados en el terreno A para los primeros dos componentes principales y los valores de  $\cos^2$  se pueden visualizar de forma gráfica en la Figura 7.

**Figura 7.** Gráfico de correlación de variables para los primeros dos componentes principales en el terreno A



Se observa que la mayoría de variables se encuentran bien representadas por los primeros 2 componentes principales según el alto valor de  $\cos^2$ , a excepción de la pendiente que presenta un  $\cos^2$  menor a 0.5, dado que está principalmente representada por el PC3.

### 3.5.2. Análisis de componentes principales en el Terreno B

**Tabla 9.** Resultados del análisis de componentes principales para el terreno B

Componente Principal	Eigenvalue	Varianza explicada (%)	Varianza explicada acumulada (%)
PC1	<b>3.91</b>	48.82	48.82
PC2	<b>1.60</b>	19.96	68.77
PC3	<b>1.13</b>	14.16	82.94
PC4	0.81	10.18	93.12
PC5	0.41	5.13	98.25
PC6	0.08	1.04	99.29
PC7	0.03	0.42	99.71
PC8	0.02	0.29	100

Al igual que en el terreno A, en el terreno B, el análisis de componentes principales arrojó eigenvalues mayores a 1 para los primeros 3 componentes principales (PC1, PC2 y PC3), quienes conjuntamente explican el 82.94% de la variación en los datos. PC1 explica 48.82%, mientras que PC2 y PC3 explican 19.96% y 14.16% respectivamente. Estos 3 componentes fueron escogidos para aplicar el clustering y delinear las zonas de manejo en el terreno B.


**Tabla 10.** Coeficientes de correlación entre cada variable y los primeros 3 componentes principales

Variable	PC1	PC2	PC3
Humedad	<b>-0.71</b>	0.19	0.21
Arena	<b>0.83</b>	0.03	0.49
Limo	<b>-0.92</b>	0.06	0.34
Arcilla	0.26	<b>0.87</b>	0.24
MO	0.46	<b>0.70</b>	<b>0.50</b>
CE	<b>0.75</b>	0.10	<b>0.59</b>
pH	<b>0.82</b>	0.001	0.14
Pendiente	<b>0.58</b>	<b>0.54</b>	0.24

**Nivel de significancia  $r > 0.50$**

Las variables que presentan mayor correlación con el componente principal 1 (PC1) son la humedad, arena, limo, conductividad eléctrica, pH y pendiente. Por otro lado, el PC2 se correlaciona con la arcilla, materia orgánica y pendiente, mientras que el componente principal 3 está relacionado con la materia orgánica y la conductividad eléctrica. Los resultados en el terreno B para los primeros dos componentes principales y los valores de  $\cos^2$  se pueden visualizar de forma gráfica en la Figura 8.

**Figura 8.** Gráfico de correlación de variables para los primeros dos componentes principales en el terreno B




La arcilla, limo, materia orgánica, arena y pH presentan una buena calidad de representación entre los primeros 2 componentes principales de acuerdo a sus valores de  $\cos^2$ , mientras que la pendiente, conductividad eléctrica y humedad presentan una calidad de representación media. En el caso de la conductividad eléctrica, esto se debe a que presenta un alto grado de correlación con el PC3. En el caso de la humedad y pendiente, posiblemente haría falta agregar más

componentes principales para alcanzar una buena calidad de representación de dichas variables.

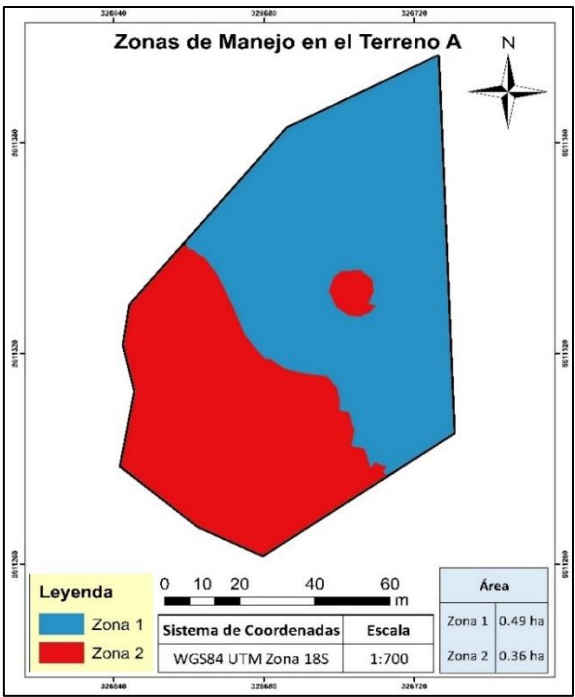
**3.6. Clustering y delineación de zonas de manejo**  
**3.6.1. Clustering y delineación de zonas de manejo en el Terreno A**

**Figura 9.** Valores de índices FPI y NCE para distinto número de zonas en el terreno A



El número de zonas que genera los valores más bajos de los índices FPI y NCE es 2, por lo que se concluye que la decisión óptima es dividir al terreno A en 2 zonas de manejo.

**Figura 10.** Zonas de manejo obtenidas para el Terreno A



Se obtuvo el mapa final de zonas de manejo para el terreno A, donde la Zona 1 abarca una superficie de 0.49 ha mientras que la Zona 2 ocupa un área de 0.36 ha.

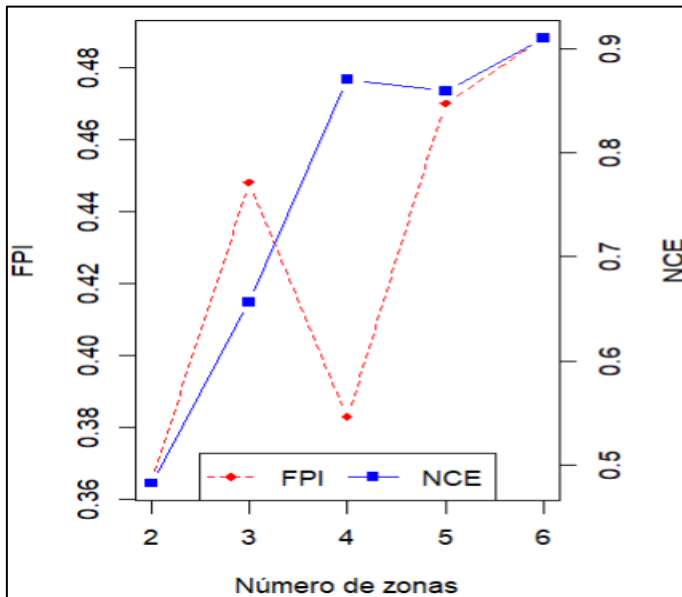
**Tabla 11.** Descripción y comparación de zonas de manejo en el terreno A

Zona	n	Arena (%)	Arcilla (%)	Limo (%)	M.O. (%)	C.E. (dS/m)	pH	Humedad (%)	Pendiente (%)
Zona 1	6	70.36 a	12.31 a	17.38 a	2.27 a	2.82 a	7.95 a	5.26 a	16.38 a
Zona 2	7	60.51 b	13.85 a	25.64 b	1.85 a	4.03 a	7.97 a	7.42 b	24.10 b
Prueba t (p-valor)	-	<b>0.0074*</b>	0.304	<b>0.0015*</b>	0.0704	0.5152	0.883	<b>0.02479*</b>	<b>&lt;0.0001*</b>

Se encontraron diferencias significativas entre las zonas para el porcentaje de arena, limo, la humedad gravimétrica y la pendiente. No se halló diferencia significativa de medias para la materia orgánica según la prueba t, pero sí se encontró diferencia entre las medianas según Mann-Whitney-Wilcoxon con un valor  $p = 0.04$ . La materia orgánica presenta una mediana de 2.25% en la Zona 1, y de 1.99% en la Zona 2. Por tanto, la Zona 1 presenta significativamente mayor arena y materia orgánica, y menor limo, humedad y pendiente que la Zona 2. La mayor proporción de arena en la Zona 1 podría indicar una mejor infiltración y drenaje, así como una menor capacidad de retención de agua (agua disponible). En cuanto a la MO, asumiendo una densidad aparente de 1.4 g/cm<sup>3</sup> y una profundidad de 30 cm, la Zona 1 contiene aproximadamente 10.9 toneladas de materia orgánica por hectárea adicionales en relación a la Zona 2. Esto podría equilibrar la capacidad de retención de agua entre las 2 zonas, dado que la Zona 1 presenta más arena pero también más materia orgánica que la Zona 2. Asimismo, asumiendo un contenido de nitrógeno de 5% de la MO y una tasa de mineralización anual de 3%, la Zona 1 tiene 16.35 kg N/ha/año adicionales a la Zona 2. Por otro lado, si bien no hubo diferencia significativa para la conductividad eléctrica, la media muestral en la Zona 2 es mayor a la encontrada en la Zona 1, con un valor de 4.03 dS/m, por lo que el suelo en la Zona 2 podría categorizarse como un suelo salino, y en la Zona 1 como moderadamente salino. Ambas zonas requieren un manejo apropiado de la salinidad para propiciar un adecuado desarrollo de los cultivos, incluyendo prácticas como el lavado de sales, riego constante, aplicación de bioestimulantes, uso de fertilizantes de bajo índice de salinidad (evitando nitrato de amonio, sulfato de amonio, urea y cloruro de potasio), materia orgánica, etc. Asimismo, ambas zonas presentan un pH cercano a 8, lo que implica una baja disponibilidad de fósforo y micronutrientes como Fe, Zn, Cu, Mn y B. Esto puede manejarse aplicando nutrientes y bioestimulantes por vía foliar, aplicando azufre o yeso al suelo (sobre todo si se comprueba sodicidad) y usando fertilizantes de reacción ácida pero baja salinidad como fosfato diamónico y fosfato monoamónico. Respecto a la pendiente, ambas zonas presentan una pendiente considerable por lo que sería adecuado aplicar prácticas de conservación de suelo como la siembra en curvas de nivel, acolchados, terrazas, entre otros.

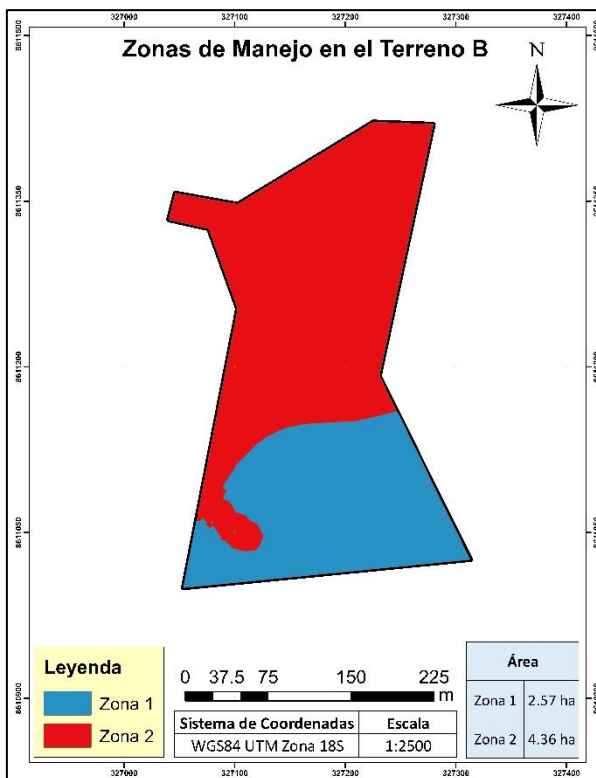
### 3.6.2. Clustering y delineación de zonas de manejo en el Terreno B

Figura 11. Valores de índices FPI y NCE para distinto número de zonas en el terreno B



La cantidad de zonas que minimiza los valores de los índices FPI y NCE es 2, por lo que se dividió al terreno B en 2 zonas de manejo.

Figura 12. Zonas de manejo obtenidas para el Terreno B





Se obtuvo el mapa final de zonas de manejo en el terreno B, donde se observa que la Zona 1 presenta una superficie de 2.57 ha, mientras que la Zona 2 abarca un área de 4.36 ha.

**Tabla 12.** Descripción y comparación de zonas de manejo en el terreno B

Variable	n	Arena (%)	Arcilla (%)	Limo (%)	M.O. (%)	C.E. (dS/m)	pH	Humedad (%)	Pendiente (%)
Zona 1	2	56.52 a	4.50 a	38.98 a	1.23 a	65.87 a	7.76 a	1.33 a	30.90 a
Zona 2	4	47.76 a	8.30 b	43.94 a	0.92 b	84.43 a	7.85 a	1.22 a	23.86 b
Prueba t (p-valor)	-	0.37	<b>0.046*</b>	0.61	<b>0.043*</b>	0.64	0.44	0.77	<b>&lt;0.0001*</b>

Se encontraron diferencias significativas ( $p < 0.05$ ) para el porcentaje de arcilla, el contenido de materia orgánica y la pendiente. El resto de variables no presentaron diferencias significativas tanto con la prueba t como con la prueba no-paramétrica Mann-Whitney-Wilcoxon. La Zona 1 presenta significativamente menor arcilla, y mayor materia orgánica y pendiente que la Zona 2. El mayor contenido de arcilla en la Zona 2 podría implicar una mayor capacidad de retención de agua y capacidad de intercambio catiónico, que implicaría una menor necesidad de fraccionamiento de fertilizantes. En cuanto a la materia orgánica, asumiendo una densidad aparente de 1.2 g/cm<sup>3</sup>, hay aproximadamente 10 toneladas de materia orgánica por hectarea adicionales en la Zona 1 en comparación con la Zona 2. Esto podría neutralizar los beneficios mencionados por la diferencia de arcilla en la Zona 2, dado que la materia orgánica también contribuye a la retención de agua y CIC. Asimismo, asumiendo un contenido de nitrógeno de 5% de la MO, y una tasa de mineralización anual de 3%, la diferencia entre ambas zonas sería de 15 kg N/ha/año. Por otro lado, la conductividad eléctrica no presentó diferencia significativa pero la media muestral en la Zona 2 fue mayor a la encontrada en la Zona 1, con 84.43 dS/m y 65.87 dS/m respectivamente. Estos valores indican que el suelo en ambas zonas es extremadamente salino y requiere prácticas de manejo como el lavado de sales, uso de fertilizantes de bajo índice de salinidad (evitar urea, nitrato de amonio, sulfato de amonio y cloruro de potasio) y un riego constante para poder establecer cultivos en el terreno, que además tendrán que ser tolerantes a condiciones de alta salinidad, como el caso de los espárragos, palma datilera, zucchini, remolacha azucarera, cebada, entre otros (FAO, 1998). Asimismo, los valores de pH mayores a 7.7 en ambas zonas implican una baja disponibilidad de fósforo y micronutrientes, que podría manejarse a través de la aplicación foliar de nutrientes y bioestimulantes, uso de fertilizantes de reacción ácida como fosfato monoamónico y fosfato diamónico, aplicación de azufre, yeso, entre otros. Para ello sería adecuado analizar más variables en el terreno como la CIC y los cationes cambiabiles. La diferencia en humedad gravimétrica podría implicar una diferencia en la lámina de riego aplicada entre las zonas, aunque los contenidos variables de arena y materia orgánica podrían ocasionar que los porcentajes de capacidad de campo de ambas zonas también difieran. Por tanto,

la fracción de agua agotada y el potencial hídrico podrían ser los mismos en ambas zonas, para valores distintos de humedad gravimétrica. Finalmente, ambas zonas presentan una pendiente pronunciada por lo que es pertinente aplicar prácticas de conservación de suelos como la siembra en curvas de nivel, acolchados, terrazas, etc.

#### **4. CONCLUSIONES**

En el presente estudio se encontró una variabilidad considerable para las distintas propiedades del suelo evaluadas en los dos terrenos de Calango. Por lo tanto, es pertinente generar mapas de suelo y agrupar el terreno en zonas de manejo que permitan adoptar un enfoque de agricultura de precisión para optimizar la aplicación de insumos, tanto en términos económicos como ecológicos. Para conseguir ese objetivo, la geoestadística y el análisis multivariado son herramientas adecuadas para el procesamiento de datos obtenidos a partir del muestreo de suelo y el correspondiente análisis fisicoquímico en laboratorio. Asimismo, para la delineación de zonas de manejo es recomendable utilizar parámetros que resuman la mayor cantidad de variabilidad posible (componentes principales), o que resulten de interés particular para fines de manejo específicos (como propiedades del suelo específicas que afectan fertilización, riego, etc.). Los mapas de distribución espacial y zonas de manejo generadas en este estudio deberían resultar útiles para la toma de decisiones concernientes a la producción agrícola, forestación y otros fines relacionados en el Fundo Calango. Se recomienda utilizar las medidas descriptivas de cada zona para la planificación de las operaciones que requieran considerar la condición del recurso suelo, además de delimitar físicamente las zonas en el terreno haciendo uso de un GPS y demarcando el límite con yeso o estableciendo un corredor biológico de plantas herbáceas y arbustivas. Asimismo, el presente estudio tuvo limitaciones durante el muestreo que impidieron una aleatorización óptima de los puntos a muestrear, por lo que se sugiere realizar un nuevo muestreo generando una grilla en cuadrícula con un distanciamiento basado en los rangos encontrados para los semivariogramas en cada terreno. Finalmente, el presente estudio no analizó todas las propiedades fisicoquímicas y biológicas relevantes para el manejo agrícola, por lo que se sugiere realizar un nuevo estudio incluyendo variables como densidad aparente, nitrógeno disponible, fósforo disponible, potasio disponible, capacidad de intercambio catiónico, cationes cambiabiles, carbonato de calcio, micronutrientes y microbiología.

#### **5. REFERENCIAS BIBLIOGRÁFICAS**

Ali, A., Ibrahim, S. (2020). Establishment of Soil Management Zones Using Multivariate Analysis and GIS. <https://www.tandfonline.com/doi/full/10.1080/00103624.2020.1836207>

Askari, S., Montazerin, N., Fazel-Zarandi, M. (2017). Generalized Possibilistic Fuzzy C-Means with novel cluster validity indices for clustering noisy data. <https://www.sciencedirect.com/science/article/abs/pii/S156849461630686X>

Bodaghabadi, M. (2018). Is it necessarily a normally distributed data for kriging? A case study: soil salinity map of Ghahab area, central Iran. [https://jdesert.ut.ac.ir/article\\_69125\\_2da835a19663f71e76d5aa11f9ff2a37.pdf](https://jdesert.ut.ac.ir/article_69125_2da835a19663f71e76d5aa11f9ff2a37.pdf)

Cambardella, C., Moorman, T., Novak, J., Parkin, T., Karlen, D., Turco, R., Konopka, A. (1994). Field-Scale Variability of Soil Properties in Central Iowa Soils. <https://acsess.onlinelibrary.wiley.com/doi/abs/10.2136/sssaj1994.03615995005800050033x>

Carrasco, P. (2010). Nugget effect, artificial or natural? <http://www.scielo.org.za/pdf/jsaimm/v110n6/06.pdf>

Celemín, J. (2009). Autocorrelación espacial e indicadores locales de asociación espacial. Importancia, estructura y aplicación. <https://www.redalyc.org/pdf/3832/383239099001.pdf>

Cotrufo, M., Ranalli, M., Haddix, M., Six, J., Lugato, E. (2019). Soil carbon storage informed by particulate and mineral-associated organic matter. <https://www.nature.com/articles/s41561-019-0484-6>

Dahler, R., McDole, R. (1987). Effect of Soil pH on Crop Yield in Northern Idaho. <https://acsess.onlinelibrary.wiley.com/doi/abs/10.2134/agronj1987.00021962007900040033x>

Diatla, A., Thomason, W., Abaye, O., Vaughan, L., Thompson, T., Lo, M., Chim, B., Bateman, S. (2018). Inoculation and Soil Texture Effects on Yield and Yield Components of Mungbean. [https://www.researchgate.net/publication/326997219\\_Inoculation\\_and\\_soil\\_texture\\_effects\\_on\\_yield\\_and\\_yield\\_components\\_of\\_mungbean](https://www.researchgate.net/publication/326997219_Inoculation_and_soil_texture_effects_on_yield_and_yield_components_of_mungbean)

FAO. (1998). Evapotranspiración del cultivo: Guías para la determinación de los requerimientos de agua de los cultivos. <https://www.fao.org/3/x0490s/x0490s.pdf>

FAO. (2009). Guía para la descripción de suelos. <https://www.fao.org/3/a0541s/a0541s.pdf>

FAO. (2020). Soil testing methods – Global Soil Doctors Programme - A farmer-to-farmer training programme. <https://doi.org/10.4060/ca2796en>

Gaster, A., Schnug, E. (2007). Geostatistics for soil science. [https://www.researchgate.net/publication/282610239\\_Geostatistics\\_for\\_soil\\_science](https://www.researchgate.net/publication/282610239_Geostatistics_for_soil_science)

Hoogsteen, M., Lantinga, E., Bakker, E., Groot, J., Titttonell, P. (2015). Estimating soil organic carbon through loss on ignition: effects of ignition conditions and structural water loss. <https://bsssjournals.onlinelibrary.wiley.com/doi/abs/10.1111/ejss.12224>

Houlong, J., Daibin, W., Chen, X., Shuduan, L., Hongfeng, W., Chao, Y., Najia, L., Yiyin, C., Lina, G. (2016). Comparisong of kriging interpolation precision between grid sampling scheme and simple random sampling scheme for precision agriculture. <https://doi.org/10.18393/ejss.2016.1.062-073>

Jamieson, P.; Porter, J.; Wilson, D. (1991). A test of the computer simulation model ARCWHEAT1 on wheat crops grown in New Zealand. *Field Crops Res.*

Juhos, K., Szabó, S., Ladányi, M. (2015). Influence of soil properties on crop yield: a multivariate statistical approach. <http://www.international-agrophysics.org/Influence-of-soil-properties-on-crop-yield-a-multivariate-statistical-approach,104156,0,2.html>

Kerry, R., Oliver, M. (2003). Average variograms to guide soil sampling. <https://www.sciencedirect.com/science/article/abs/pii/S030324340400042X?via%3Dihub>

Khan, H. (2020). Delineation of Management Zones for Site-Specific Information about Soil Fertility Characteristics through Proximal Sensing of Potato Fields. <https://www.mdpi.com/2073-4395/10/12/1854>

Khosla, R., Inman, D., Westfall, D., Reich, R., Frasier, M., Mzuku, M., Koch, B., Hornung, A. (2008). A synthesis of multi-disciplinary research in precision agriculture: site-specific management zones in the semi-arid western Great Plains of the USA. <https://pubag.nal.usda.gov/catalog/120275>

Laekemariam, F., Kibret, K., Mamo, T., Shiferaw, H. (2018). Accounting Spatial Variability of Soil Properties and Mapping Fertilizer Types Using Geostatistics in Southern Ethiopia. <https://www.tandfonline.com/doi/full/10.1080/00103624.2017.1421656?cookieSet=1>

Lavallee, J., Soong, J., Cotrufo, M. (2020). Conceptualizing soil organic matter into particulate and mineral-associated forms to address global change in the 21st century. [https://www.researchgate.net/publication/336285888\\_Conceptualizing\\_soil\\_organic\\_matter\\_into\\_particulate\\_and\\_mineral-associated\\_forms\\_to\\_address\\_global\\_change\\_in\\_the\\_21\\_st\\_century](https://www.researchgate.net/publication/336285888_Conceptualizing_soil_organic_matter_into_particulate_and_mineral-associated_forms_to_address_global_change_in_the_21_st_century)

Metwally, M. (2019). Soil Properties Spatial Variability and Delineation of Site-Specific Management Zones Based on Soil Fertility Using Fuzzy Clustering in a Hilly Field in Jianyang, Sichuan, China. <https://www.mdpi.com/2071-1050/11/24/7084>

Nawar, S., Corstanje, R., Halcro, G. Mulla, D., Mouazen, A. (2017). <https://experts.umn.edu/en/publications/delineation-of-soil-management-zones-for-variable-rate-fertilizat>

Osborne, J. (2010). Improving your data transformations: Applying the Box-Cox transformation. <https://core.ac.uk/download/pdf/239584602.pdf>

Ramos, F., Santos, R., Campelo, J., De Souza, J. (2017). Defining management zones based on soil attributes and soybean productivity. <https://www.scielo.br/j/rcaat/a/P6VTbHyZNQRthBhqX89PkqL/?format=pdf&lang=en>

Schenatto, K., Godoy, E., Leones, C., Bier, V., Betzek, N., Gavioli, A. (2016). Data interpolation in the definition of management zones. <https://www.redalyc.org/journal/3032/303243563005/html/>

Schenatto, K., Godoy, E., Leones, C., Bier, V., Betzek, N., Gavioli, A. (2016). Data interpolation in the definition of management zones. [https://www.researchgate.net/publication/292608279\\_Data\\_interpolation\\_in\\_the\\_definition\\_of\\_management\\_zones](https://www.researchgate.net/publication/292608279_Data_interpolation_in_the_definition_of_management_zones)

Schweizer, S., Mueller, C., Höschen, C., Ivanov, P., Kögel-Knabner, I. (2021). The role of clay content and mineral surface area for soil organic carbon storage in an arable toposequence. <https://link.springer.com/article/10.1007/s10533-021-00850-3>

Sharma, S. (1996) Applied Multivariate Techniques. [https://www.scirp.org/\(S\(i43dyn45teexjx455qlt3d2q\)\)/reference/ReferencesPapers.aspx?ReferenceID=1556224](https://www.scirp.org/(S(i43dyn45teexjx455qlt3d2q))/reference/ReferencesPapers.aspx?ReferenceID=1556224)

Sigua, G., Hudnall, W. (2008). Kriging analysis of soil properties. <https://link.springer.com/article/10.1007/s11368-008-0003-7>

Sonmez, S., Buyuktas, D., Okturen, F., Citak, S. (2008). Assessment of different soil to water ratios (1:1, 1:2.5, 1:5) in soil salinity studies. [https://www.researchgate.net/publication/223567009\\_Assessment\\_of\\_different\\_soil\\_to\\_water\\_ratios\\_11\\_125\\_15\\_in\\_soil\\_salinity\\_studies](https://www.researchgate.net/publication/223567009_Assessment_of_different_soil_to_water_ratios_11_125_15_in_soil_salinity_studies)

Stravidou, E., Hastings, A., Webster, R., Robson, P. (2016). The impact of soil salinity on the yield, composition and physiology of the bioenergy grass *Miscanthus x giganteus*. <https://onlinelibrary.wiley.com/doi/full/10.1111/gcbb.12351>

Szatmári, G., Pásztor, L. (2016). Geostatistics in soil mapping – A review. [https://www.researchgate.net/publication/303843272\\_Geostatistics\\_in\\_soil\\_mapping\\_-\\_A\\_review\\_Geostatisztika\\_a\\_talajterkepezesben](https://www.researchgate.net/publication/303843272_Geostatistics_in_soil_mapping_-_A_review_Geostatisztika_a_talajterkepezesben)

Tsekouras, G., Sarimveis, H. (2004). A new approach for measuring the validity of the fuzzy c-means algorithm. <https://www.sciencedirect.com/science/article/abs/pii/S0965997804000602>

Wilding, L. (1985). Spatial variability: Its documentation, accommodation and implication to soil surveys. <http://www.sciepub.com/reference/105122>

Yuan, L., Chang, S., Cui, S., Zhang, Q. (2019). Liming effects on soil pH and crop yield depend on lime material type, application method and rate, and crop species: a global meta-analysis. [https://www.researchgate.net/publication/327188728\\_Liming\\_effects\\_on\\_soil\\_p](https://www.researchgate.net/publication/327188728_Liming_effects_on_soil_p)

[H and crop yield depend on lime material type application method and rate and crop species a global meta-analysis](#)

Zeraatpisheh, M. (2020). Integration of PCA and Fuzzy Clustering for Delineation of Soil Management Zones and Cost-Efficiency Analysis in a Citrus Plantation. <https://www.mdpi.com/2071-1050/12/14/5809>